Docente: Dra. Marcela Riccillo

Alumno Marcelo Berra
Parameters P=0.70 Grupo 3

Trabajo Práctico Final – Data Mining y Machine Learning

Parte A

1. Abra la base shuttle de la librería MASS. Se quiere predecir el uso o no del autolander (variable a predecir: “use”). Renombre la base como “base”.

```
> library(MASS)
> base=shuttle
```

2. Indique de qué trata el problema

```
Problema del Autolander del Transbordador Espacial

El problema trata acerca de

determinar cuando conviene

utilizar el sistema de

aterrizaje en forma automatica.
```

3. Muestre un head de la base.

```
> head(base)
  stability error sign wind   magn vis  use
1     xstab    LX   pp head  Light  no auto
2     xstab    LX   pp head Medium  no auto
3     xstab    LX   pp head Strong  no auto
4     xstab    LX   pp tail  Light  no auto
5     xstab    LX   pp tail Medium  no auto
6     xstab    LX   pp tail Strong  no auto
```

4. Comente las variables, cantidad de registros, cantidad de registros de cada clase.

Info del Data Frame

	Cantidad
Registros	256
Variables	7

	CantVariables
Categoricas	6
Decision	1

`	CantRegistros
Entrenamiento	253
Test	3

Definicion de las Variables

Variable	Definicion	Valores	Tipo
Categoricas			
stability	Posicion estable o no	stab / xstab	Cualitativa/Nominal
error	tamaño del error	MM / SS / LX / XL	Cualitativa/Nominal
sign	señal de error	pp / nn positive or negative	Cualitativa/Nominal
wind	viento de donde	Head / tail	Cualitativa/Nominal
magn	fuerza del viento	Light / Medium / Strong / Out of Range	Cualitativa/Nominal
vis	visibilidad	Yes / no	Cualitativa/Nominal
Decision			
use	usar el autolander	auto / noauto	Cualitativa/Nominal

```
> summary(base)
 stability   error   sign       wind         magn     vis          use
 stab :128   LX:64   nn:128   head:128   Light :64   no :128   auto  :145
 xstab:128   MM:64   pp:128   tail:128   Medium:64   yes:128   noauto:111
             SS:64                       Out   :64
             XL:64                       Strong:64
```

5. Realice un gráfico de barras de la variable “use”.

```
> barplot(table(shuttle$use), col=c(“green”, ”red”))
```

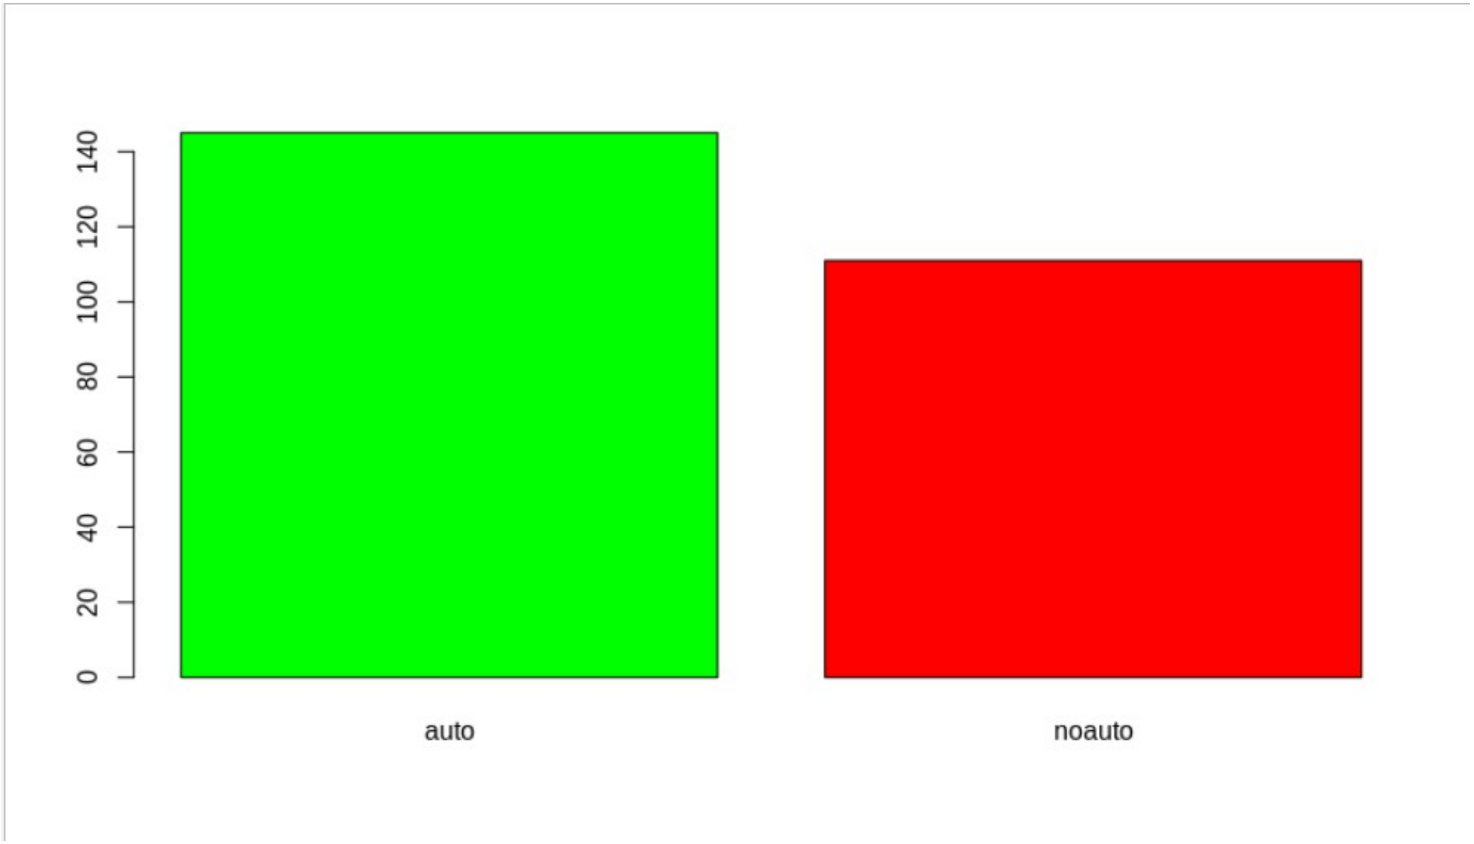

Parte B

6. Cargue la librería caret, setee la semilla=8 y particione la base en un conjunto de entrenamiento y uno de testeo, utilizando la instrucción createDataPartition de la librería caret.
Setee p=(0.70). Indique el código R utilizado.

```
> library(caret)
> set.seed(8)
> particion=createDataPartition(y=shuttle$use, p=0.7, list=FALSE)
> train=shuttle[particion, ]
> test=shuttle[-particion, ]
```

7. Muestre un head, str y un summary del conjunto de entrenamiento y del conjunto de testeo.
¿Cuántos registros quedaron en cada conjunto?
¿Cuántos registros de cada clase quedaron en cada conjunto?

```
> head(train)
   stability error sign wind   magn vis  use
1      xstab    LX   pp head  Light  no auto
2      xstab    LX   pp head Medium  no auto
5      xstab    LX   pp tail Medium  no auto
7      xstab    LX   nn head  Light  no auto
11     xstab    LX   nn tail Medium  no auto
12     xstab    LX   nn tail Strong  no auto
```

```
> str(train)
'data.frame':    180 obs. of  7 variables:
 $ stability: Factor w/ 2 levels "stab","xstab": 2 2 2 2 2 2 2 2 2 2 ...
 $ error    : Factor w/ 4 levels "LX","MM","SS",..: 1 1 1 1 1 1 4 4 4 4 ...
 $ sign     : Factor w/ 2 levels "nn","pp": 2 2 2 1 1 1 2 2 2 2 ...
 $ wind     : Factor w/ 2 levels "head","tail": 1 1 2 1 2 2 1 1 1 2 ...
 $ magn     : Factor w/ 4 levels "Light","Medium",..: 1 2 2 1 2 4 1 2 4 2 ...
 $ vis      : Factor w/ 2 levels "no","yes": 1 1 1 1 1 1 1 1 1 1 ...
 $ use      : Factor w/ 2 levels "auto","noauto": 1 1 1 1 1 1 1 1 1 1 ...


> summary(train)
 stability  error   sign      wind        magn     vis         use
 stab :92   LX:42   nn:88   head:89   Light :45   no :89   auto  :102
 xstab:88   MM:51   pp:92   tail:91   Medium:49   yes:91   noauto: 78
            SS:44                     Out   :40
            XL:43                     Strong:46



> head(test)
   stability error sign wind   magn vis  use
3      xstab    LX   pp head Strong  no auto
4      xstab    LX   pp tail  Light  no auto
6      xstab    LX   pp tail Strong  no auto
8      xstab    LX   nn head Medium  no auto
9      xstab    LX   nn head Strong  no auto
10     xstab    LX   nn tail  Light  no auto
```

```
> str(test)
'data.frame':    76 obs. of  7 variables:
 $ stability: Factor w/ 2 levels "stab","xstab": 2 2 2 2 2 2 2 2 2 2 ...
 $ error    : Factor w/ 4 levels "LX","MM","SS",..: 1 1 1 1 1 1 4 4 4 2 ...
 $ sign     : Factor w/ 2 levels "nn","pp": 2 2 2 1 1 1 2 1 1 2 ...
 $ wind     : Factor w/ 2 levels "head","tail": 1 2 2 1 1 2 2 1 2 1 ...
 $ magn     : Factor w/ 4 levels "Light","Medium",..: 4 1 4 2 4 1 1 2 1 1 ...
 $ vis      : Factor w/ 2 levels "no","yes": 1 1 1 1 1 1 1 1 1 1 ...
 $ use      : Factor w/ 2 levels "auto","noauto": 1 1 1 1 1 1 1 1 1 1 ...
```

```
> summary(test)
 stability  error   sign      wind        magn     vis         use
 stab :36   LX:22   nn:40   head:39   Light :19   no :39   auto  :43
 xstab:40   MM:13   pp:36   tail:37   Medium:15   yes:37   noauto:33
            SS:20                     Out   :24
            XL:21                     Strong:18
```

Cant.de Registros	
Train	180
Test	76

Cant.de Reg.x Clase		
	auto	noauto
Train	102	78
Test	43	33

Parte C

8. Cree un Árbol de Decisión (con librería rpart) para modelar el problema planteado.
   Indique el código R utilizado.

```
> library(rpart)
> arbol=rpart(use~., train, method="class")
```

9. Grafique el árbol de decisión resultante con la instrucción rpart.plot de la librería rpart.plot.

```
> library(rpart.plot)
> rpart.plot(arbol, extra=101, type=4, cex=0.8)
```

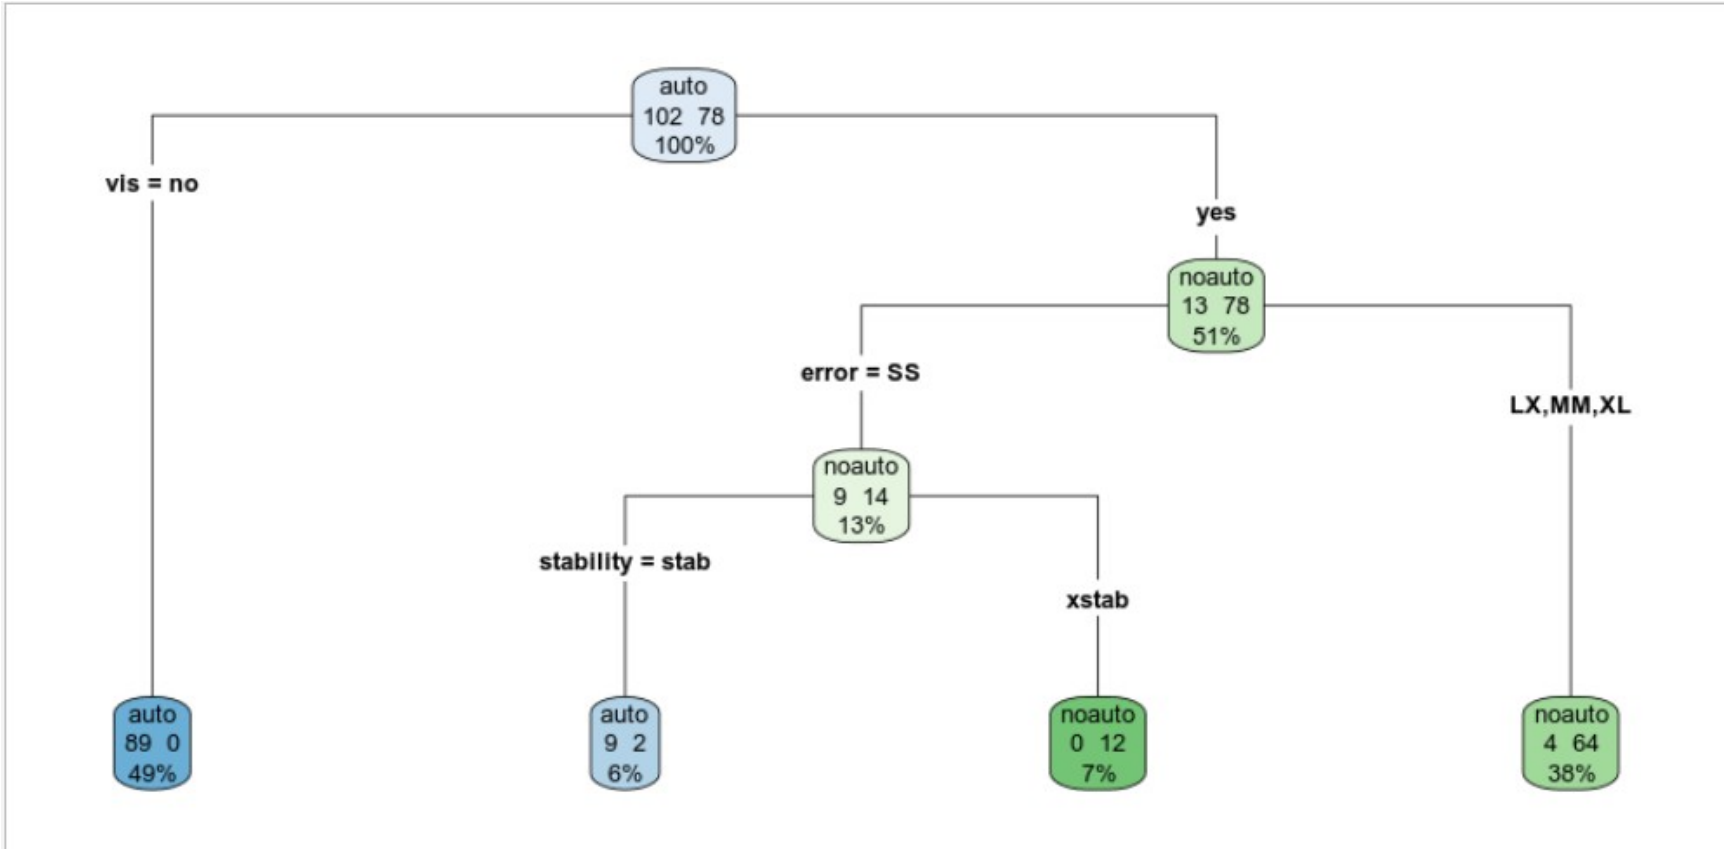

10. Calcule la matriz de confusión utilizando la instrucción confusionMatrix de la librería caret. Muestre una imagen de los resultados obtenidos.

```
> pred=predict(arbol, test, type="class")
> confusionMatrix(pred, test$use)

  Confusion Matrix and Statistics

            Reference                      Accuracy : 0.9605
  Prediction auto noauto                     95% CI : (0.8889, 0.9918)
      auto     42      2        No Information Rate : 0.5658
      noauto    1     31        P-Value [Acc > NIR] : 5.333e-15

                                          Kappa : 0.9194

                                 Mcnemar's Test P-Value : 1

                                    Sensitivity : 0.9767
                                    Specificity : 0.9394
                                 Pos Pred Value : 0.9545
                                 Neg Pred Value : 0.9687
                                     Prevalence : 0.5658
                                 Detection Rate : 0.5526
                           Detection Prevalence : 0.5789
                              Balanced Accuracy : 0.9581

                               'Positive' Class : auto
```

11. ¿Cuántos registros quedaron bien y mal clasificados?

	Clasificados
Bien	42 + 31 = 73
Mal	1 + 2 = 3

12. ¿Cómo fue la perfomance del modelo? (accuracy, sensibilidad y especificidad)

```
Accuracy      =  (42+31) / (42+31+1+2) =      0.9605
Sensibilidad  =   42 / (42 + 1) =             0.9767
Especificidad =   31 / (31 + 2) =             0.9394
```

13. Según el árbol de decisión creado, ¿cuándo debería usarse el autolander?

```
Cuando

  No hay visibilidad    o

  Hay visibilidad, tamano del error es SS y se encuentra en posicion Estable
```

Parte D

14. Setee la semilla=8 y cree una Red Neuronal (con librería nnet) para modelar el problema planteado, con size=6 y maxit=5000. Indique el código R utilizado.

```
> library(nnet)
> set.seed(8)
> red=nnet(use~., train, size=6, maxit=5000)
# weights:  73
initial  value 123.906943
iter  10 value 3.359699
iter  20 value 0.052594
iter  30 value 0.001692
iter  40 value 0.000349
final  value 0.000080
converged
```

15. Grafique la Red Neuronal resultante.

```
> library(NeuralNetTools)
> plotnet(red)
```

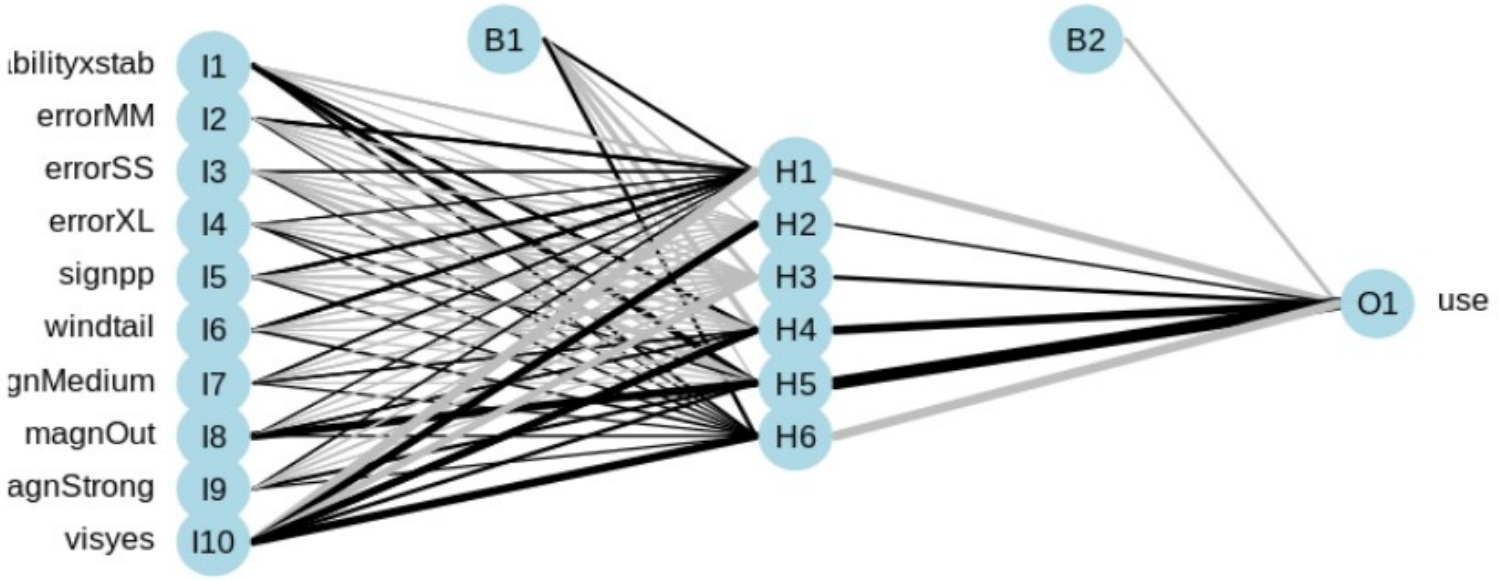

16. Calcule la matriz de confusión utilizando la instrucción confusionMatrix de la librería caret. Muestre una imagen de los resultados obtenidos.

```
> pred=predict(red, test, type="class")
> library(caret)
> confusionMatrix(factor(pred), test$use)

  Confusion Matrix and Statistics

            Reference                      Accuracy : 0.9737
  Prediction auto noauto                     95% CI : (0.9082, 0.9968)
      auto     43      2        No Information Rate : 0.5658
      noauto    0     31        P-Value [Acc > NIR] : 2.766e-16

                                          Kappa : 0.9461

                                 Mcnemar's Test P-Value : 0.4795

                                    Sensitivity : 1.0000
                                    Specificity : 0.9394
                                 Pos Pred Value : 0.9556
                                 Neg Pred Value : 1.0000
                                     Prevalence : 0.5658
                                 Detection Rate : 0.5658
                           Detection Prevalence : 0.5921
                              Balanced Accuracy : 0.9697

                               'Positive' Class : auto
```

17. ¿Cuántos registros quedaron bien y mal clasificados? ¿Cómo fue la perfomance del modelo? (accuracy, sensibilidad y especificidad)

	Clasificados		
Bien	43 + 31	=	74
Mal	0 + 2	=	2

```
Accuracy      =  (43+31) / (43+31+0+2) =      0.9737

Sensibilidad  =   43 / (43 + 0) =               1

Especificidad =   31 / (31 + 2) =             0.9394
```

Conclusion

```
Comparando las matrices de confusion del Arbol y la Red Neuronal,
veo que la Red Neuronal tiene mayor Exactitud, Sensibilidad y Especificidad.

Con lo cual, en este caso, utilizaria la Red Neuronal
en vez del Arbol de Decision.
```

```
#-------------------------------------------------------------------------------
library(MASS)
base=shuttle
str(base)
fix(base)
head(base)
summary(base)
barplot(table(shuttle$use), col=c("green", "red"))
#-------------------------------------------------------------------------------
library(caret)
set.seed(8)
particion=createDataPartition(y=shuttle$use, p=0.7, list=FALSE)
train=shuttle[particion, ]
test=shuttle[-particion, ]
head(train)
str(train)
summary(train)
head(test)
str(test)
summary(test)
#-------------------------------------------------------------------------------
library(rpart)
arbol=rpart(use~., train, method="class")
summary(arbol)
library(rpart.plot)
rpart.plot(arbol, extra=101, type=4, cex=0.8)
pred=predict(arbol, test, type="class")
table(pred, test$use)
confusionMatrix(pred, test$use)
#-------------------------------------------------------------------------------
library(nnet)
set.seed(8)
red=nnet(use~., train, size=6, maxit=5000)
library(NeuralNetTools)
plotnet(red)
pred=predict(red, test, type="class")
library(caret)
confusionMatrix(factor(pred), test$use)
#-------------------------------------------------------------------------------
```